

Trabajo Practico N° 3

Minería de datos

Objetivo

El objetivo de este trabajo práctico es integrar los conocimientos adquiridos en las unidades 5 y 6 en un problema real de **clasificación multiclase**, asociado a la recomendación de cultivos agrícolas en función de parámetros de suelo y clima. La variable objetivo es *Cultivo* (tipo de cultivo recomendado, con 12 clases).

Descripción del conjunto de datos

El conjunto de datos *dxCropRecommendation.csv*¹ contiene **1210 muestras** y **8 columnas**. Las 7 variables predictoras son:

Variable	Descripción
Nitrogeno	Contenido de nitrógeno en suelo
Fosforo	Contenido de fósforo en suelo
Potasio	Contenido de potasio en suelo
Temperatura	Temperatura en °C
Humedad	Humedad relativa en %
pH	pH del suelo
Lluvia	Precipitaciones en mm
Cultivo	Cultivo recomendado (variable objetivo)

La variable objetivo *Cultivo* tiene 12 clases: Arroz, Banana, Café, Garbanzo, Granada, GranoNegro, Lenteja, Maíz, Mango, Manzana, Naranja y Uva.

Importante: El conjunto de datos ha sido modificado intencionalmente.

Actividades

1. **Preparación de datos.** Realizar un análisis exploratorio de datos (EDA) sobre el conjunto de datos *dxCropRecommendation.csv*: visualizar distribuciones de cada variable predictora, analizar correlaciones, verificar la distribución de clases de la variable *Cultivo*. Detectar y reportar: (a) los valores faltantes, indicando en qué columnas se encuentran y qué estrategia se utiliza para tratarlos (eliminación, imputación por media/mediana, etc.), justificando la decisión; (b) los registros duplicados, indicando cuántos son y qué se hace con ellos; (c) posibles outliers. **Estandarizar las características numéricas** (*StandardScaler*), ya que SVM es sensible a la escala de las variables. Codificar la variable objetivo si corresponde (*LabelEncoder*). Utilizar *random_state=13* en todas las operaciones que lo requieran.
2. **SVM con kernel lineal.** Realizar la predicción de la variable *Cultivo* utilizando SVC (*kernel='linear'*). Explorar el parámetro de regularización *C*, probando al menos 5 valores en escala logarítmica (por ejemplo: 0.01, 0.1, 1, 10, 100). Para cada valor

¹Conjunto de datos original: <https://www.kaggle.com/conjunto-de-datos/atharvaingle/crop-recommendation-conjunto-de-datos> (modificado para este TP)

Trabajo Practico N° 3

Minería de datos

de C, evaluar el rendimiento mediante **validación cruzada estratificada con k=5** (*StratifiedKfold*) sobre todo el conjunto de datos limpio. Reportar para cada configuración: Precisión (Precision weighted), Exhaustividad (Recall weighted) y Exactitud (Accuracy), indicando la media y la desviación estándar obtenida en los 5 folds. Se utiliza el promedio weighted dado que el conjunto de datos presenta un leve desbalance entre clases. Seleccionar la mejor configuración y justificar la elección.

3. **SVM con kernel gaussiano (RBF).** Realizar la predicción de la variable *Cultivo* utilizando *SVC (kernel='rbf')*. Explorar los parámetros de regularización C y ancho del kernel *gamma*, probando al menos 4 valores para cada uno en escala logarítmica (por ejemplo: C = {0.1, 1, 10, 100}, gamma = {0.001, 0.01, 0.1, 1}). Para cada combinación, evaluar el rendimiento mediante **validación cruzada estratificada con k=5**. Reportar: Precisión (Precision weighted), Exhaustividad (Recall weighted) y Exactitud (Accuracy), indicando media y desviación estándar. Presentar los resultados en formato de tabla o heatmap para visualizar la interacción entre C y *gamma*. Seleccionar la mejor configuración y justificar.
4. **Random Forest.** Realizar la predicción de la variable *Cultivo* utilizando *RandomForestClassifier*. Explorar los parámetros: cantidad de estimadores (*n_estimators*: probar al menos 4 valores, por ejemplo 50, 100, 200, 500) y máxima profundidad de los árboles (*max_depth*: probar al menos 4 valores, por ejemplo 5, 10, 20, None). Para cada combinación, evaluar el rendimiento mediante **validación cruzada estratificada con k=5**. Reportar: Precisión (Precision weighted), Exhaustividad (Recall weighted) y Exactitud (Accuracy), indicando media y desviación estándar. Analizar la importancia de las variables (*feature_importances_*) del mejor modelo obtenido. Seleccionar la mejor configuración y justificar.
5. **Comparación de modelos.** Realizar una tabla comparativa de los tres modelos (SVM lineal, SVM RBF y Random Forest) con las métricas obtenidas por la mejor configuración de cada algoritmo. Incluir la **matriz de confusión** del mejor modelo de cada algoritmo (puede generarse utilizando uno de los folds de la validación cruzada o mediante un split adicional 80/20 con *random_state=13*). Seleccionar y justificar cuál es el modelo más adecuado para este problema, considerando las métricas, la estabilidad entre folds (desviación estándar), la interpretabilidad y el tiempo de entrenamiento.

Nota: la validación cruzada estratificada con k=5 implica que el conjunto de datos completo (una vez limpio) se divide en 5 particiones (folds) manteniendo la proporción de clases en cada una. Cada fold actúa como conjunto de test una vez, mientras los otros 4 se usan para entrenamiento. Las métricas se reportan como la media $\pm$ desviación estándar de los 5 folds. La exploración de hiperparámetros debe realizarse dentro de este esquema (por ejemplo, usando **cross_val_score** o **GridSearchCV** con el mismo **StratifiedKfold**).

Trabajo Practico N° 3

Minería de datos

Presentación

La entrega es por grupos de dos estudiantes y se entrega un archivo por grupo.

Cualquier integrante del grupo puede hacer la entrega mediante el campus de la materia.

El informe deberá tener una cabecera en la que se indique: año, materia, integrantes. Además, deberá contar con una sección de conclusiones al final del mismo.

El formato del informe deberá ser **.ipynb** (Jupyter Notebook) y no debe contener las definiciones teóricas ni el significado de los parámetros de los métodos dados en clase.

Utilizar *random_state=13* en todos los modelos, particiones y validaciones cruzadas para garantizar la reproducibilidad.

Las gráficas mostradas en el informe deben contener una explicación de lo observado y si es coherente con la hipótesis previa. La cantidad de gráficas debe ser acotada (no más de 3-4 por actividad) y representativa.

Las entregas fuera del plazo establecido no serán consideradas salvo excepciones previamente justificadas por el grupo.

Comentario Final: se valorará especialmente la detección y tratamiento correcto de los problemas del conjunto de datos (valores faltantes, duplicados), la correcta interpretación de los resultados, la justificación de las decisiones tomadas y la calidad de las visualizaciones.